



Matéria: Pesquisa Operacional  
Professor Dr.: Rafael Marconi Ramos  
Alunos: Kelvin Sousa e Elson Gois  
Período: 8º Semestre

# RELATÓRIO TÉCNICO

## Sistema de Otimização Multi-Algoritmo para Maximização

**Disciplina:** Pesquisa Operacional

**Aluno:** Kelvin Sousa (58992) e Elson Gois (60771)

**Arquivo executável:** provab2.exe

**Configuração:** 10 parâmetros inteiros [1, 1000]

## 2. INTRODUÇÃO

Este relatório apresenta a implementação e análise comparativa de três algoritmos de otimização aplicados ao problema de maximização do executável provab2.exe. O sistema desenvolvido executa os algoritmos de forma sequencial, utilizando paralelização inteligente de threads quando aplicável, e realiza cronometragem detalhada com registro de data e hora em cada iteração.

O problema consiste em maximizar uma função objetivo implementada no executável provab2.exe, que recebe 10 parâmetros inteiros no intervalo [1, 1000] e retorna um valor de fitness. Foram executadas três corridas independentes do sistema completo, comparando os seguintes algoritmos:

- Pattern Search (Hooke-Jeeves): Algoritmo de busca direta sequencial
- Particle Swarm Optimization (PSO): Algoritmo de inteligência de enxame paralelizado
- Híbrido (PSO + Pattern Search): Combinação de exploração global e refinamento local

O arquivo este no repositório git: <https://github.com/kelvin-sous/PO/blob/main/README.md>, commit: e494ea3c.

## 2. METODOLOGIA

### 2.1 Configuração do Sistema

O sistema foi desenvolvido em Python utilizando as seguintes tecnologias:

- NumPy para operações vetoriais e manipulação de arrays
- Multiprocessing para detecção automática de threads disponíveis
- Datetime para registro temporal preciso de cada iteração
- Subprocess para execução do programa externo

### 2.2 Detecção Automática de Recursos

O sistema detectou automaticamente 20 threads disponíveis no processador e realizou a divisão inteligente:

- Pattern Search: 0 threads (algoritmo sequencial por natureza)
- Particle Swarm: 10 threads (50% dos recursos disponíveis)
- Híbrido (PSO + OS): 10 threads na fase PSO, 0 threads na fase Pattern Search

### 2.3 Configuração dos Algoritmos

Algoritmo	Parâmetros	Máx. Iterações
Pattern Search	Delta=1.0, delta_min=1e-6	50
Particle Swarm	n_particles=20, w=0.7, c1=1.5, c2=1.5	30
Híbrido	PSO: 20 partículas / PS: delta=0.1	PSO: 20 / PS: 20

## 2.4 Ponto Inicial

Todos os algoritmos iniciaram com o mesmo ponto:  $x_0 = [50.5, 50.5, 50.5, 50.5, 50.5, 50.5, 50.5, 50.5, 50.5, 50.5]$ , representando valores centrais do espaço de busca  $[1, 1000]$ .

## 3. RESULTADOS EXPERIMENTAIS

### 3.1 Execução 1

Algoritmo	Fitness	Iterações	Tempo (min)
Pattern Search	520.000	31	3.48
Particle Swarm	1440.000	31	4.37
Híbrido	885.000	19	5.42
MELHOR	Particle Swarm	1440.000	13.31 min total

### 3.2 Execução 2

Algoritmo	Fitness	Iterações	Tempo (min)
Pattern Search	520.000	31	3.54
Particle Swarm	902.000	31	4.38
Híbrido	1194.000	19	5.41
MELHOR	Híbrido	1194.000	13.36 min total

### 3.3 Execução 3

Algoritmo	Fitness	Iterações	Tempo (min)
Pattern Search	520.000	31	3.49
Particle Swarm	906.000	31	4.34
Híbrido	1341.000	18	5.38
MELHOR	Híbrido	1341.000	13.25 min total

## 4. ANÁLISE COMPARATIVA

### 4.1 Resumo Estatístico

Algoritmo	Fitness Médio	Desvio Padrão	Tempo Médio (min)
Pattern Search	520.000	0.000	3.50
Particle Swarm	1082.667	306.181	4.36
Híbrido	1140.000	242.847	5.40

### 4.2 Performance dos Algoritmos

Pattern Search:

O algoritmo Pattern Search apresentou resultados consistentes, mas limitados. Em todas as três execuções, convergiu para o mesmo fitness de 520.0 com solução  $[51.5, 51.5, 51.5, 51.5, 51.5, 51.5, 51.5, 51.5, 51.5, 51.5]$ . Esta consistência absoluta (desvio padrão zero) indica que o algoritmo sempre encontra o mesmo mínimo local próximo ao ponto inicial, não conseguindo explorar outras regiões do espaço de busca. O tempo médio de execução foi de 3.50 minutos, o mais rápido entre os três algoritmos.

#### Particle Swarm Optimization:

O PSO demonstrou alta variabilidade nos resultados (desvio padrão de 306.18), obtendo fitness de 1440.0, 902.0 e 906.0 nas três execuções. Esta variação é característica de algoritmos estocásticos e demonstra a capacidade de exploração global do espaço de busca. O melhor resultado geral do estudo (fitness 1440.0) foi obtido pelo PSO na primeira execução. A paralelização com 10 threads resultou em tempo médio de 4.36 minutos, apenas 24.6% mais lento que o Pattern Search, mas com qualidade de solução muito superior.

#### Híbrido (PSO + Pattern Search):

O algoritmo híbrido apresentou o melhor desempenho médio (fitness 1140.0) e menor variabilidade entre os algoritmos estocásticos (desvio padrão de 242.85). A combinação da exploração global do PSO com o refinamento local do Pattern Search resultou em soluções consistentemente superiores. Obteve o melhor resultado em duas das três execuções (1194.0 e 1341.0). O tempo de execução foi de 5.40 minutos, refletindo a execução sequencial das duas fases (PSO paralelizado + PS sequencial).

## 5. CONCLUSÕES

### 5.1 Principais Descobertas

- 1. O algoritmo Híbrido demonstrou ser a escolha mais robusta, combinando boa performance média (1140.0) com consistência relativa (desvio padrão de 242.85). Venceu em 2 das 3 execuções.
- 2. O PSO apresentou o melhor resultado absoluto (1440.0), mas com maior variabilidade, tornando-o adequado quando múltiplas execuções são viáveis.
- 3. O Pattern Search, embora rápido, ficou preso em mínimo local (520.0) próximo ao ponto inicial, demonstrando limitação para problemas complexos de alta dimensionalidade.
- 4. A paralelização com threads foi efetiva: o PSO utilizou 10 threads e manteve tempo competitivo (4.36 min) com qualidade superior.

### 5.2 Relação Custo-Benefício

Algoritmo	Fitness/Minuto	Avaliação
Pattern Search	148.57	Baixo desempenho
Particle Swarm	248.32	Bom custo-benefício
Híbrido	211.11	Melhor equilíbrio

### 5.3 Recomendações

- Para otimização com restrição de tempo (execução única): Utilizar o algoritmo Híbrido, que oferece o melhor equilíbrio entre performance e consistência.
- Para otimização com múltiplas execuções disponíveis: Executar o PSO múltiplas vezes e selecionar o melhor resultado, aproveitando sua capacidade de exploração global.
- Para otimização em tempo real ou recursos limitados: O Pattern Search pode ser adequado apenas se o problema for unimodal ou o ponto inicial for próximo do ótimo global.

### 5.4 Implementação Técnica

O sistema implementado demonstrou eficiência na utilização de recursos computacionais:

- Detecção automática de 20 threads disponíveis no processador
- Divisão inteligente: 50% para PSO, 50% para Híbrido, 0% para Pattern Search
- Aproveitamento de 100% dos recursos durante fase PSO
- Cronometragem detalhada com data/hora em cada iteração para análise temporal precisa
- Registro completo do histórico de convergência para análise posterior

